Regresyon

2.Hafta

y | x_1 | x_2 | x_3

Regress → Bağlamak

$y' = f(x) + \varepsilon$

Örnek: $y' = 2 + 3x_1 + 2x_2 + 4x_3 + \varepsilon$

$y' = a + bx + \varepsilon$ = basit doğrusal regresyon

$y' = a + bx^2 + cx + \varepsilon$ = basit eğrisel regresyon

$y' = ax^b + \varepsilon$

$y' = a + bx_1 + cx_2 + \varepsilon$ = çoklu doğrusal regresyon

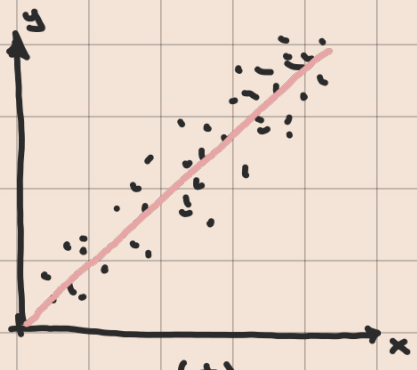
Kavramın Önemi: Özellikle 2.Dünya Savaşından sonra İstatistikçi, matematikçi ve ekonomistler birçok alanda ki belirsizlikleri bilimsel yöntemlerle tahmin edebilmek için istatistik tahmin teknikleri geliştirmeye başlamıştır. Bu teknikler arasında ilişkiye dayanan tahmin tekniği olarak da ifade edebileceğimiz regresyon, tahmin edilecek değişkenin tahmininde bu değişkeni etkileyen faktörlerin saptanıp ilişkinin matematik bir fonksiyonla ifade edilmesine dayanır. Bu fonksiyona regresyon denklemi adı verilmektedir.

En genel hali ile regresyon denklemi: $y' = f(x) + \varepsilon$

Bu denklem yardımı ile açıklayıcı değişkenlerin (bağımsız değişkenler) çeşitli değerlerine karşılık bağımlı değişkenin (sonuç, cevap, y) ulaşacağı değer tahmin edilir.

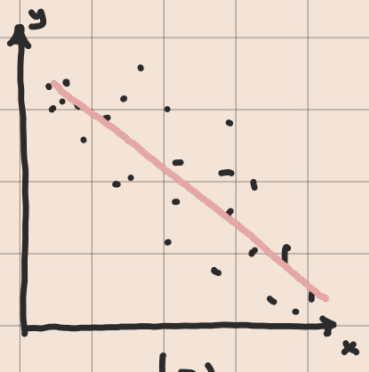
Regresyon analizi başlığı altında karşılaşılan 2. önemli analiz korelasyon analizidir. Korelasyon, bağımlı değişken ile bağımsız değişken veya değişkenler arasında ki ilişkinin gücünü ve yönünü gösteren bir katsayıdır. Hangi bağımsız değişkenin gücü daha fazla ise hem regresyon modellemesinde hem de bağımlı değişken üzerinde oluşturulacak politikalarda bu değişken üzerinde daha fazla durulmalıdır.

Serpilme Diyagramı (Scatter Plot): Bağımsız değişkenler ile bağımlı değişken arasında ki ilişkinin görselleştirilmesi amacıyla serpme diyagramı kullanılır.



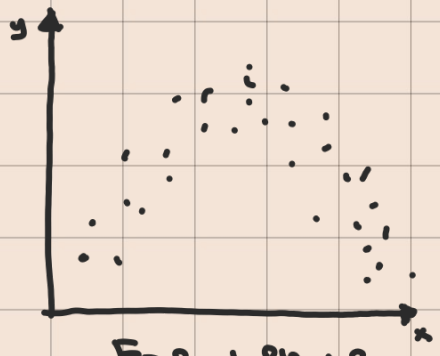
(+)

$\rho(x,y) > 0,70$



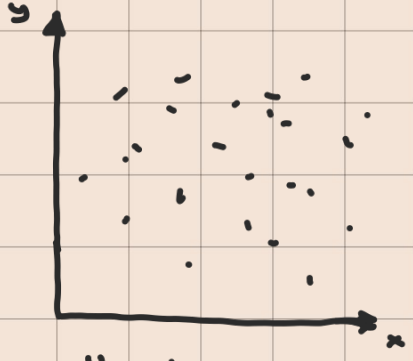
(-)

$\rho(x,y) < 0,50$



Eğrisel ilişki

$\rho(x,y) \sim 0$



Korelasyon yok

Dolayısıyla regresyon analizinin en önemli aşaması değişkenler arasında ki ilişkinin yapısını inceleyerek kurulan regresyon modeline doğru karar vermektir (eğrisel bir ilişki, doğrusal bir fonksiyonla modellenemez)

Regresyon Analizi bağımsız değişken sayısına göre;

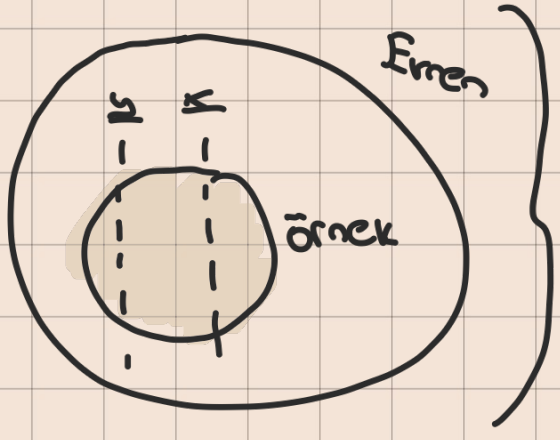
* Basit regresyon analizi ($y' = a + bx + \varepsilon$)
* Çoklu regresyon analizi ($y' = a + b_1x_1 + b_2x_2 + \varepsilon$)

Fonksiyon tiplerine göre;

* Doğrusal regresyon analizi
* Doğrusal olmayan (eğrisel) regresyon analizi ($y' = a + bx^2 + cx + \varepsilon$) ($y' = a \cdot x^b$)

Verilerin kaynağına göre;

* Ana kütle verileri ile regresyon analizi
* Örnek verileri ile regresyon analizi
* Zaman serilerinde regresyon analizi



Anakütle	Örnek
N	n
μ	$\bar{x}$
σ	S
ρ	r
A	a
B	b

$\rho(x,y)$ → Anakütle korelasyon

$y' = A + Bx + \varepsilon$ → Anakütle regresyon

$r(x,y)$ → Örneklem korelasyon

$y' = a + bx + \varepsilon$ → örneklem regresyon

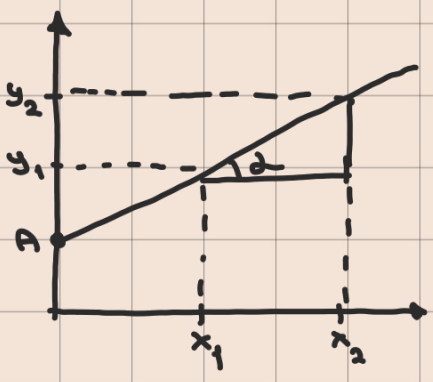
Bağımlı ve bağımsız değişken sayısının birden çok olduğu durumlarda çoklu regresyon analizinin yeliştirilmiş hali olan kanonikse korelasyon analizi kullanılır.

Bağımlı değişkenin iki şıklı olması durumunda ise lojistik regresyon analizi, 3 veya daha fazla şıklı olduğu durumda ise multinominal lojistik regresyon kullanılır.

3.Hafta

Basit Regresyon ve Korelasyon Analizi: Ana kütle ve örnek verileri ile yapılan istatistik araştırmalarında tekniklerin uygulanması açısından fark yoktur. Örnek verileri ile analiz yapılmışsa teknikler uygulandıktan sonra örnekleme teorisinden yararlanılarak ana kütle parametrelerin testleri,

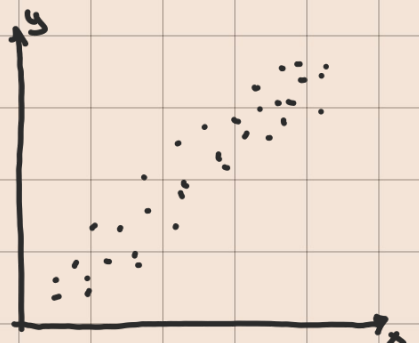
tahminleri yapılır. Basit regresyon analizinde y bağımlı değişkenlerin tek bir bağımsız değişken x ile arasında ki ilişkinin doğrusal bir fonksiyonla ifade edilmesi süreci gerçekleşir. $y = Ax + Bx + E$ Ana kütle regresyon denklemi örneklem ise $y = a + bx + e$ ile ifade edilir. A, regresyon denkleminin sabitidir (constant) ve $x = 0$ olduğunda regresyon doğrusunun y'yi kestiği noktayı göstermektedir. B ise doğrusal fonksiyonun eğimidir.



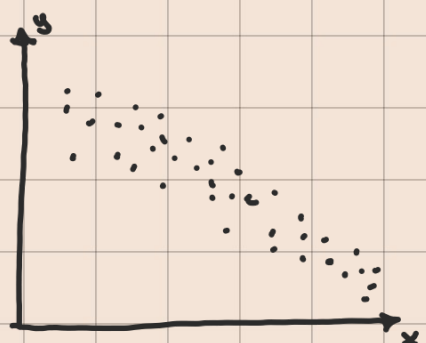
$$\tan\alpha = \frac{y_2 - y_1}{x_2 - x_1}$$

Regresyon analizinde B katsayısı bağımsız değişken x de ki 1 birimlik değişmenin bağımlı değişken y'de ne kadarlık değiştiğini gösterir.

Regresyon analizine başlamadan önce fonksiyon tipinin belirlenmesi için serpilme diyagramı çizilir. Basit doğrusal regresyon analizinde x ve y arasında aşağıda ki iki durumdan birisiyle karşılaşılır.



(+) yönlü doğrusal ilişki $B > 0$



(-) yönlü doğrusal ilişki $B < 0$

$B = 0$ olması iki değişken arasında doğrusal ilişkinin olmadığı anlamına gelir.

Regresyon denkleminde e veya E ile gösterilen değer hata (error) terimidir. Buna regresyon analizinde artık veya kalıntı (residuel) denir. $E = y - y'$ ile hesaplanır. y', y nin x ile açıklanabilen kısmını, $y - y'$ ise x ile açıklanamayan kısmını gösterir.

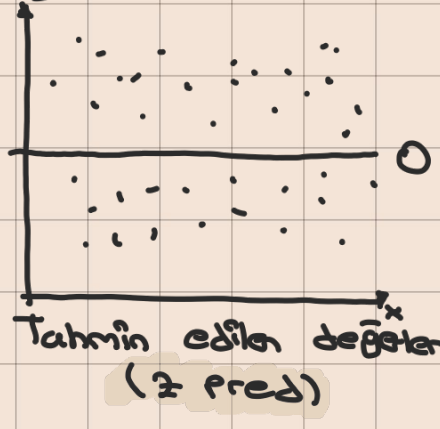
Tanım Ve Varsayımlar:

1) Bağımlı değişken y, bağımsız değişken x'e belli ölçüde bağlıdır. y değişkeni tesadüfi, x değişkeni ise araştırmacı tarafından seçilen belirlenmiş bir değişkendir.

2) Her x değerine karşılık y değerlerinin bir alt seti vardır. Bu y alt setlerinin dağılım ortalaması E(y|x) olan normal bir dağılım y'ler tesadüfi olduğu için y-y' olan ε'lerde tesadüfi ve bağımsız kabul edilir. Buna hatalar arasında otokorelasyon olmaması varsayımı adı verilir. SPSS'de otokorelasyon varsayım kontrolü Durbin-Watson testi ile yapılır.

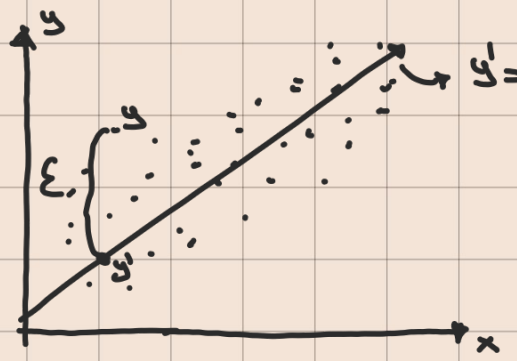
3) Belirli x değerleri karşısında y değerlerinin alt setlerinin varyansları birbirine eşittir. Buna homoskedastisite (eş varyanslık varsayımı) denir.

Bu varsayımın sağlanmasına heteroskedastisite denir. SPSS'de bu varsayımı kontrol etmek için tahmin edilen değerlerin x ekseninde artıkların ise y ekseninde olduğu grafik çizdirilir. Sağılım grafiği olan bu şekilde görüntünün 0 etrafında rassal bir şekilde seçilmesi gere



Doğrusal Regresyon denklemin yorumu: Serpilme diyagramında doğrusal bir yapı gözlenmişse x'den y'e göre matematik fonksiyonun doğrusal olduğuna karar verilebilir. Ancak bu gözlem noktaları arasında çok sayıda doğru geçebilir.

Bu fonksiyonlardan en uygunu y gözlem değerine en yakın tahmini y' değerini veren(minimum) hataya sahip doğrusal fonksiyon olacak



$y' = A + Bx$

$$\varepsilon = \sum \varepsilon_i^2 = \sum (y_i - y_i')^2$$

$$\varepsilon = \sum (y_i - A - Bx_i)^2$$

Kısmi türevlerini alır isek;

$$\frac{\partial \varepsilon}{\partial A} = 0 \quad , \quad \frac{\partial \varepsilon}{\partial B} = 0$$

$$\frac{\partial \varepsilon}{\partial A} = 2\sum (y_i - A - Bx_i).(-1) = 0 \quad \xrightarrow{-2\text{'ye bölünür}} \quad \sum (y_i - A - Bx_i) = 0$$

$$\frac{\partial \varepsilon}{\partial B} = 2\sum (y_i - A - Bx_i).(-x_i) = 0 \quad \sum (x_i y_i - Ax_i - Bx_i^2) = 0$$

$$\Rightarrow \begin{matrix} \sum y_i - \sum A - \sum Bx_i = 0 \\ \sum x_i y_i - \sum Ax_i - \sum Bx_i^2 = 0 \end{matrix} \Rightarrow \begin{matrix} \sum y_i - N.A - B.\sum x_i = 0 \\ \sum x_i y_i - A\sum x_i - B\sum x_i^2 = 0 \end{matrix}$$

$$\Rightarrow \begin{matrix} \sum y = N.A + B\sum x \\ \sum xy = A\sum x + B\sum x^2 \end{matrix}$$

y	x	xy	x^2
$\sum y$	$\sum x$	$\sum xy$	$\sum x^2$

5. Hafta

Regresyon Denklemi ile Yapılacak Tahminlerin Standart Hatası: Bu değer genellikle S harfi ile gösteilmektedir. İndisler kullanılarak hangi fonksiyonun veya hangi regresyon denkleminin hatası olduğu belirlenir.

S_{yx}: Basit Doğrusal regresyon hatası.

$S_{yx x^2}$: Eğrisel regresyon hatası.

! $\hat{S}$ ana kütle verileri ile hesaplanması gereken verilerin örnek verileri ile hesaplanmış halidir.

$$S_{yx} = \sqrt{\frac{\sum (y - y')^2}{N}} \quad , \quad \hat{S}_{yx} = \sqrt{\frac{\sum (y - y')^2}{n - k}}$$

k: regresyondaki parametre sayısı

! Basit regresyon için

$$\hat{S}_{yx} = \sqrt{\frac{\sum (y - y')}{n - 2}}$$

Standart hatanın 0 veya 0'a yakın olması, fonksiyonun iyi seçildiğini ve aynı zamanda x değişkeninin y üzerinde önemli etkisi olduğunu gösterir. Şayet fonksiyon ve açıklayıcı değişken iyi seçilmişse y' değeri gözlenen y değerine çok yakın çıkacak ve düşük bir standart hata elde edilecektir. Aksi halde hata fazla çıkacaktır bu durumda fonksiyon tipi değiştirilebilir ve korelasyon değerinin değerlendirilmesi ile birlikte x'in açıklayıcılığı düşük ise x değiştirilebilir veya başka bağımsız değişkenler ile desteklenip çoklu regresyon yapılabilir.

Korelasyon Analizi: Korelasyon analizi bağımsız değişkenler tarafından bağımlı değişkenin kendi içinde ki değişkenlikle açıkladığı kısmı ortaya çıkmaktadır.

Korelasyon analizi bağımlı ve bağımsız değişken arasında ki ilişkiyi oran (yüzde) olarak gösteren korelasyon katsayısının hesaplanmasına dayanmaktadır. Ana kütle verileri ile çalışıldığında:

ρ_{xy}: Anakütle basit korelasyon katsayısı

r_{xy}: Örnekleme " " "

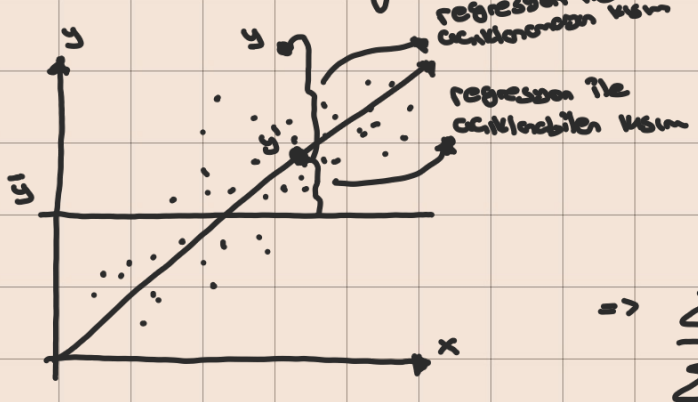
Korelasyon katsayıları da standart hatada olduğu gibi fonksiyon tipini ve bağımsız değişkenlerin gösterdiği indislerdir.

Örneğin r_{yx} basit doğrusal korelasyon katsayısını r_{yxx^2} ise korelasyon indexini gösterir.

Örnek:

x_1: bağımlı
x_2, x_3: bağımsız
} Çoklu regresyon

$r_{1,23}$: Çoklu korelasyon katsayısı
$r_{12,3}$: Kısmi " "



$$\underbrace{\sum(y-\bar{y})^2}_{\text{y'de ki toplam değişkenlik}} = \underbrace{\sum(y-y')^2}_{\text{Regresyon ile açıklanamayan kısım}} + \underbrace{\sum(y'-\bar{y})^2}_{\text{Regresyon ile açıklanabilen kısım}}$$

$$\Rightarrow \frac{\sum(y-\bar{y})^2}{\sum(y-\bar{y})^2} = \frac{\sum(y-y')^2}{\sum(y-\bar{y})^2} + \frac{\sum(y'-\bar{y})^2}{\sum(y-\bar{y})^2}$$

$$\Rightarrow 1-\frac{\Sigma(y-y')^2}{\Sigma(y-\bar{y})^2}=\rho^2 \quad , \quad \rho=\sqrt{1-\frac{\Sigma(y-y')^2}{\Sigma(y-\bar{y})^2}}$$

x	y

$y'=A+Bx$ ise

1) Uygunluk ve varsayım kontrolü
→ Serpilme diyagramı
→ $\rho=\frac{\Sigma(x-\bar{x})(y-\bar{y})}{\sqrt{\Sigma(x-\bar{x})^2 . \Sigma(y-\bar{y})^2}}$

2) EKK (En küçük kareler) uygula, A ve B'yi bul.

3) x'i $y'=A+Bx$ de yerine yaz y hesapla

4) $S_{yx}=\sqrt{\frac{\Sigma(y-y')^2}{N}}$ hesapla $\cong 0$

5) $\rho_{yx}=\sqrt{1-\frac{\Sigma(y-y')^2}{\Sigma(y-\bar{y})^2}}$ hesapla $\rho^2=R^2$

ρ doğrusal korelasyon katsayısının karesi R^2 belirlilik katsayısı olarak bilinir ve basit regresyonda bu değerin 0,70 ve üzeri olması arzu edilir. Örnek olarak $R^2=0,82$ çıkması y de ki değişkenliğin %82'sini x tarafından açıklanabildiği şeklindedir.

Bir anakütle regresyonu yukarıda ki adımlar takip edilerek yapılır. Analiz sonucunda S_{yx} 0'a yakın, S_{yx} 1'e yakın ise bu denklem tahmin ve politikalarda kullanılabilir.

Regresyon Denkleminde Tahmin ve Politikalar: Yeni bir x_0 değerine karşılık y'nin değerinin ne olabildiğine karşın öncelikle nokta tahmini yapılır.

1-) $y'_0=A+Bx_0$ nokta tahmini, ancak bu tahminin bir de standart hatası vardır ve bu hatanın da tahmine ilave edilmesi gereklidir.

2-) **Aralık Tahmini:** $\hat{y}_0=y'_0 \mp 2.S_{yx}$ ile $\hat{y}_{0alt} \longleftrightarrow \hat{y}_{0üst}$

Örnek: İstatistik dersinde ki başarının matematik dersinde ki başarıya bağlı olup olmadığına göre 8 öğrenci seçilmiş ve 10 üstünden aldıkları notlar aşağıda ki gibi saptanmıştır.

İstatistik	Matematik
1	2
2	3
3	5
5	6
6	7
7	10
8	7
8	8

Regresyon analizini yaparak matematik dersinden 4 alan bir öğrencinin İstatistik dersinden kaç alacağını %95 olasılık ile tahmin edin.iz.

N=8

1) Korelasyon Katsayısı:

$$\rho(x,y) = \frac{\Sigma(x-\mu_x).(y-\mu_y)}{\sqrt{\Sigma(x-\mu_x)^2.\Sigma(y-\mu_y)^2}}$$

$$\mu_y = \frac{1+2+3+\dots+8}{8} = \frac{40}{8} = 5$$

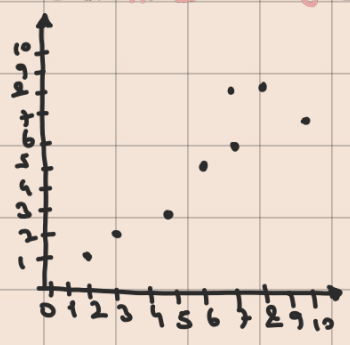
$$\mu_x = \frac{2+3+5+\dots+8}{8} = \frac{48}{8} = 6$$

$y-\mu_y$	$x-\mu_x$	$(y-\mu_y)^2$	$(x-\mu_x)^2$	$(x-\mu_x).(y-\mu_y)$
-4	-4	16	16	16
-3	-3	9	9	9
-2	-1	4	1	2
0	0	0	0	0
1	-1	1	1	-1
2	4	4	16	8
3	1	9	1	3
3	2	9	4	6
		52	48	45

$$\rho(x,y) = \frac{\Sigma(x-\mu_x).(y-\mu_y)}{\sqrt{\Sigma(x-\mu_x)^2.\Sigma(y-\mu_y)^2}} = \frac{45}{\sqrt{48,52}} = 0,90$$

x ile y arasında pozitif yönde kuvvetli doğru ilişki vardır.

2) Serpilme Diyagramı:



3) Ekk uygulanışı:

$$\Sigma y = N.A + B.\Sigma x$$
$$\Sigma x = A\Sigma x + B\Sigma x^2$$

$N=8$

y	x	xy	x^2
1	2	2	4
2	3	6	9
3	5	15	25
5	6	30	36
6	7	42	49
7	10	70	100
8	7	56	49
8	8	64	64
	48	285	336

$$40 = 8A + 48B$$
$$285 = 48A + 336B$$
$$-240 = -48A - 288B$$
$$+285 = +48A + 336B$$
$$45 = 48B$$
$$B = \frac{45}{48} = 0,9375$$
$$A = 0,625$$

$$y' = -0,625 + 0,9375x$$

4) Regresyon Denkleminin Hatasını Bulma:

y	y' → x'leri y'ye yazdım	y-y'	$(y-y')^2$
1	1,25	-0,25	0,0625
2	2,18	-0,18	0,0324
3	4,06	-1,06	1,1236
5	5	0	0,0049
6	3,93	0,07	3,0625
7	8,75	-1,75	4,2849
8	5,93	2,07	1,2769
8	6,87	1,13	9,8125

$$S_{yx} = \sqrt{\frac{\Sigma(y-y')^2}{N}} = \sqrt{\frac{9,8125}{8}} = 1,10$$

5) Belirtik Katsayısı R^2 hesabı:

$$R = \sqrt{1 - \frac{\Sigma(y-y')^2}{\Sigma(y-\bar{y})^2}} = \sqrt{1 - \frac{9,8125}{52}} = 0,90$$

İstatistik dersinde alınan notların değişimi matematik dersinden alınan notları %81 oranda açıklamaktadır.

$R^2 = \%81$

6) Tahmin ve Politikalar:

Nokta: $x=4$ için $y' = -0,625 + 0,9375.(4) = 3,125$

Aralık: $\hat{y} = y' \pm z_{\alpha/2}.S_{yx}$

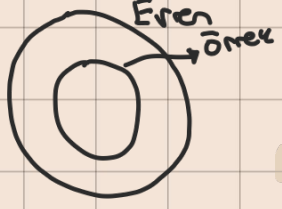
$\hat{y} = 3,125 \pm 1,96.(1,075)$

$\hat{y}_{alt} = 0,9543$

$\hat{y}_{üst} = 5,2957$

Mat dersinden 4 alan bir öğrencinin ders notu %95 ihtimal 0,95 ile 5,29 arasında yer alır.

Örnek verileri ile basit doğrusal regresyon analizi: Anakütleyi oluşturan tüm birimler gözlenemediği zaman örnek verileri ile regresyon analizi yapıldığında anakütle regresyon denkleminin korelasyon katsayısının ve denklemin hatasının tahmini elde edilebilir. Dolayısıyla örnek verileri ile regresyon yapıldıktan sonra regresyon denkleminin ve korelasyon katsayısının evrende geçerli olup olmadığının hipotez testleri yapılmak zorundadır. Hipotez testleri tahmin ve politikalara geçmeden önce yapılması gereken bir adımdır.



$y' = A + Bx$, ρ_{yx} , $S_{yx} = \sqrt{\frac{\sum (y-y)^2}{N}}$

$y' = a + bx$, r_{yx}

$\hat{S}_{yx} = \sqrt{\frac{\sum (y-y')^2}{n-k}}$

Regresyon katsayısının testi:

1) H_0: $B = 0$
   H_1: $B \neq 0$
2) $\alpha = 0,95$
3) $n > 30$ $z = \frac{b}{S_b}$
   $n < 30$ $t = \frac{b}{S_b}$

S_b = Regresyon katsayısı b'nin standart hatasıdır

$S_b = \frac{S'_{yx}}{\sqrt{\sum (x-\bar{x})^2}}$ ile hesaplanır.

4) $z_{\alpha/2}$ veya $t_{\alpha/2;n-2} \geq z$ veya t ise H_0 kabul
   $z_{\alpha/2}$ veya $t_{\alpha/2;n-2} < z$ veya t ise H_0 Red

Korelasyon katsayısının testi:

1) H_0: $\rho_{yx} = 0$
   H_1: $\rho_{yx} \neq 0$
2) $\alpha = 0,95$
3) $\underset{\text{veya } z}{t} = \sqrt{\frac{n-2}{1-r^2_{yx}}}$

! 5,5'de ki adım.